PENGEMBANGAN MODEL REKOMENDASI PENGADAAN SUKU CADANG PEMBANGKIT LISTRIK DENGAN MENGGUNAKAN *LONG SHORT-TERM MEMORY* (LSTM)

TESIS

Karya tulis sebagai salah satu syarat
untuk memperoleh gelar Magister dari
Institut Teknologi Bandung

Oleh
AHMAD MUSHAWIR
NIM: 20922307
(Program Studi Magister Sains Komputasi)

INSTITUT TEKNOLOGI BANDUNG
Januari 2024

PENGEMBANGAN MODEL REKOMENDASI PENGADAAN SUKU CADANG PEMBANGKIT DENGAN MENGGUNAKAN *LONG SHORT-TERM MEMORY* (LSTM)

Oleh
Ahmad Mushawir
NIM: 20922307
(Program Studi Magister Sains Komputasi)

Institut Teknologi Bandung

Menyetujui
Pembimbing

Tanggal 11 Juni 2024

(Dr. rer. nat. Sparisoma Viridi, S.Si.)

ABSTRAK

PENGEMBANGAN MODEL REKOMENDASI PENGADAAN SUKU CADANG PEMBANGKIT DENGAN MENGGUNAKAN *LONG SHORT-TERM MEMORY* (LSTM)

Oleh

Ahmad Mushawir

NIM: 20922307

(Program Studi Magister Sains Komputasi)

Pada industri pembangkit listrik, ketersediaan suku cadang yang tepat waktu adalah hal yang krusial untuk memastikan kelancaran operasional dan efisiensi finansial. PT PLN Nusantara Power (PLN NP), sebagai salah satu perusahaan pembangkit listrik di Indonesia, menghadapi tantangan signifikan dalam mengelola pengadaan suku cadang yang efektif dan efisien. Keterlambatan dalam pengadaan suku cadang sangat berpotensi untuk menyebabkan gangguan operasional yang berujung pada kerugian finansial yang besar. Untuk memitigasi hal ini, penelitian ini mengembangkan model prediktif berbasis Long Short-Term Memory (LSTM) yang bertujuan untuk memperbaiki dan mempercepat proses pengadaan suku cadang.

Model LSTM dipilih karena kemampuannya yang teruji dalam memprediksi data sekuensial, yang sangat sesuai untuk menghadapi kompleksitas dan dinamika pengadaan suku cadang di PLN NP. Penelitian ini menggunakan data historis dari sistem Manajemen Aset Perusahaan (EAM) untuk melatih model, memungkinkan prediksi yang lebih akurat mengenai jenis, jumlah, dan waktu kebutuhan suku cadang di masa depan. Melalui pendekatan ini, model diharapkan tidak hanya dapat mengurangi risiko operasional tetapi juga meningkatkan efisiensi pengeluaran.

Hasil penelitian ini diharapkan memberikan wawasan baru dalam pengelolaan rantai pasok suku cadang di sektor pembangkit listrik dan menawarkan metodologi yang dapat diadaptasi oleh industri serupa. Selain itu, dengan mengintegrasikan teknologi prediksi yang canggih, PLN NP dapat mengoptimalkan ketersediaan suku cadang, meminimalisir downtime, dan mendukung keberlanjutan operasional pembangkit listrik. Kajian ini juga menyoroti pentingnya adaptasi dan pengembangan terus menerus dari sistem manajemen rantai pasok dalam menghadapi tantangan yang dinamis.

Kata kunci: pengadaan, suku cadang, rekomendasi, lstm, *neural network.*

Bab I Pendahuluan

Dalam konteks pembangunan ekonomi, pembangunan infrastruktur energi yang berkelanjutan dan efisien menjadi kebutuhan mendesak bagi negara-negara yang mengalami pertumbuhan ekonomi pesat, termasuk Indonesia. Seiring dengan pertumbuhan ekonomi dan peningkatan konsumsi energi, sektor pembangkitan listrik di negara ini juga mendapat perhatian khusus sebagai salah satu upaya untuk meningkatkan pasokan listrik yang cukup kepada masyarakat. Di tengah tantangan seperti ini, PT PLN Nusantara Power (PLN NP) yang merupakan salah satu perusahaan yang bergerak dalam bidang pembangkit listrik di Indonesia juga menghadapi beberapa hambatan operasional yang cukup besar, terutama yang terkait dengan pengelolaan pengadaan suku cadang agar dapat berjalan secara efektif dan efisien.

Penelitian ini akan memberikan pandangan mendalam mengenai pengaruh sistem pengelolaan pengadaan suku cadang terhadap efisiensi operasional di PLN NP, dengan inovasi pengembangan model prediktif terkini untuk memperbaiki dan mempercepat proses tersebut. Penelitian ini juga berusaha mengatasi kesenjangan pengetahuan dan menyajikan solusi praktis yang dapat digunakan untuk membantu PLN NP dalam memperkuat keandalan operasi pembangkitan listriknya di Indonesia.

I.1 Latar Belakang

Pembangkit listrik memainkan peran penting dalam menyediakan pasokan energi yang stabil dan andal untuk mendukung kebutuhan masyarakat dan kegiatan industri. Di Indonesia, sektor pembangkitan energi telah mengalami ekspansi cepat yang didorong oleh pertumbuhan ekonomi yang signifikan dan permintaan energi listrik yang semakin meningkat. Sebagai salah satu yang berperan sebagai komponen utama dalam infrastruktur listrik, PLN Nusantara Power (PLN NP) bertugas mengoperasikan dan memelihara pembangkit listrik di seluruh nusantara.

Pengelolaan pembangkit listrik penuh dengan tantangan, salah satunya adalah pengadaan suku cadang tepat waktu. Keterlambatan dalam mendapatkan komponen penting ini dapat mengganggu operasi, menyebabkan pemadaman listrik atau kapasitas yang berkurang, yang tidak hanya mengganggu pasokan listrik tetapi juga dapat mengakibatkan kerugian finansial yang cukup besar.
Masalah keterlambatan ini diperparah dengan sulitnya dalam memprediksi kebutuhan suku cadang di masa depan. Mengingat beragamnya sistem pembangkitan energi yang terletak di lingkungan yang berbeda dan fluktuasi permintaan energi yang tidak dapat diprediksi, memprediksi suku cadang mana yang akan dibutuhkan, kapan, dan dalam jumlah berapa sangatlah kompleks. Kesalahan dalam prediksi ini dapat menyebabkan pembelian suku cadang yang tidak efisien, penumpukan yang tidak perlu, atau kekurangan pada waktu kritis.

Data historis dari sistem Manajemen Aset Perusahaan (EAM) PLN NP menunjukkan bahwa banyak *work order* yang ditandai sebagai "*urgent*" dan "*emergency*" tertunda karena proses pengadaan yang lambat atau masalah pengiriman. Hal ini menunjukkan bahwa sistem yang ada saat ini kurang memadai untuk memberikan rekomendasi pembelian barang yang tepat waktu atau efisien.

Studi terbaru menyoroti bahwa pendekatan konvensional dalam pengadaan suku cadang, seperti yang dibahas oleh Bloch and Budris (2021), tidak lagi memadai untuk menangani kompleksitas dan ketidakpastian dalam manajemen inventaris pembangkit listrik. Untuk mengatasi tantangan ini, model rekomendasi berbasis *machine learning*, khususnya jaringan Long Short-Term Memory (LSTM), muncul sebagai solusi yang menjanjikan. Poin yang dikemukakan oleh Bhattacharyya, Kulkarni, dan Mishra (2022) tentang integrasi antara manufaktur tambahan dengan sistem berbasis LSTM menyoroti potensi besar dalam meningkatkan ketahanan rantai pasokan dan efisiensi pengadaan suku cadang.

Di samping itu, literatur juga menyoroti bahwa model berbasis LSTM telah terbukti sukses dalam berbagai konteks industri, tidak hanya pembangkit energi namun seperti industri kemasan plastik, seperti yang diilustrasikan oleh Rahmi, Gabriel,

dan Farizal (2022). Hal ini menunjukkan fleksibilitas dan adaptabilitas model LSTM dalam memecahkan masalah pengadaan suku cadang di berbagai sektor industri.

Lebih jauh lagi, studi oleh Sherstinsky (2020) dan Salazar et al. (2022) menunjukkan bahwa penggunaan model berbasis LSTM dapat menghasilkan peningkatan signifikan dalam manajemen inventaris dan tingkat layanan melalui ramalan permintaan yang akurat dan manajemen stok yang efisien. Namun, tantangan seperti kualitas data dan kompleksitas integrasi tetap menjadi hambatan yang perlu diatasi.

Sebagai respons terhadap tantangan yang sebelumnya disebutkan, pengembangan model prediktif untuk pengadaan suku cadang menjadi sangat penting bagi PLN NP. Model ini bertujuan untuk memanfaatkan data pembelian historis untuk membuat rekomendasi pengadaan yang lebih akurat dan efisien. Dengan memprediksi kebutuhan suku cadang di masa depan dengan lebih baik, perusahaan dapat menghindari keterlambatan, meminimalkan gangguan operasional, dan mengoptimalkan efisiensi pengeluaran. Menurut studi yang dilakukan oleh Bloch dan Budris (2021) yang membahas tantangan ketersediaan dan pengadaan suku cadang, menekankan perlunya model yang lebih canggih untuk menangani kompleksitas manajemen inventaris di pembangkit listrik.

Lebih lanjut, pengembangan model ini menawarkan manfaat jangka panjang bagi PLN NP dalam merencanakan strategi pemeliharaan dan pengelolaan aset. Dengan pemahaman yang lebih mendalam tentang pola penggunaan suku cadang, perusahaan dapat meningkatkan proses pemeliharaan, memperpanjang masa pakai aset, dan mengurangi biaya operasional jangka panjang.

Tidak hanya itu, integrasi LSTM dengan teknik lanjutan lainnya, seperti fuzzy logic, genetic algorithms, dan reinforcement learning, telah menunjukkan potensi untuk meningkatkan ketepatan prediksi dan efisiensi proses pengadaan suku cadang (Misra et al., 2023). Penelitian juga telah menyoroti adaptabilitas model

rekomendasi pengadaan suku cadang berbasis LSTM di berbagai industri selain pembangkitan energi, seperti otomotif, manufaktur, dan transportasi (Gupta et al., 2023).

Selain itu, beberapa penelitian mengusulkan pengembangan sistem yang mengintegrasikan LSTM dengan pemantauan real-time untuk memberikan umpan balik langsung terhadap kondisi operasional dan permintaan suku cadang, memungkinkan penyesuaian cepat terhadap perubahan kondisi yang terjadi (Wang et al., 2023). Hal ini menyoroti peran penting teknologi digital dan pemantauan real-time dalam meningkatkan efisiensi proses pengadaan suku cadang.

Dalam mengoptimalkan pengadaan suku cadang, penting untuk mempertimbangkan peran manusia dalam mengambil keputusan. Beberapa penelitian menekankan pentingnya kolaborasi antara sistem prediktif berbasis LSTM dengan keputusan manusia dalam mengoptimalkan proses pengadaan dan meminimalkan risiko (Smith et al., 2022).

Mengingat urgensi dan kompleksitas masalah ini, penelitian ini bertujuan untuk memberikan kontribusi signifikan kepada PLN NP dan industri pembangkitan energi secara lebih luas. Dengan fokus pada pengembangan model rekomendasi pengadaan suku cadang yang inovatif dan efektif, studi ini berharap dapat menyediakan solusi berkelanjutan untuk tantangan yang dihadapi dalam pengelolaan aset pembangkit listrik.

I.2 Rumusan Masalah

Beberapa rumusan masalah pada penelitian ini adalah sebagai berikut:

1. Bagaimana mengembangkan model rekomendasi pembelian suku cadang yang efektif berdasarkan data historis PO untuk mengoptimalkan proses pengadaan suku cadang di PLN Nusantara Power?
2. Sejauh mana model rekomendasi pembelian suku cadang mampu mengurangi risiko *trip* atau *derating* pada pembangkit listrik PLN Nusantara Power?

3. Apakah LSTM model terbaik yang dapat digunakan dalam melakukan rekomendasi pembelian suku cadang jika dibandingkan dengan model *time-series* lain?

I.3 Tujuan Penulisan

Penelitian ini bertujuan untuk memberikan kontribusi yang signifikan dalam meningkatkan efisiensi dan keandalan operasional pembangkit listrik, serta mengoptimalkan pengeluaran perusahaan. Dengan menjawab pertanyaan-pertanyaan di atas, diharapkan penelitian ini dapat memberikan wawasan yang berharga bagi PLN Nusantara Power dan industri pembangkit listrik secara keseluruhan.

I.4 Batasan Masalah

Penelitian ini memiliki batasan masalah:

1. Data yang digunakan pada penelitian ini adalah data historis *purchase order* (PO) suku cadang dari sistem EAM PLN Nusantara Power dalam rentang waktu 2012-2023.
2. Suku cadang yang digunakan pada penelitian ini adalah suku cadang dengan *criticality* A, B dan C. Masing-masing diambil 2 buah pada masing-masing *criticality*.
3. Metode prediksi pembelian suku cadang dikembangkan menggunakan metode *Long Short-Term Memory (LSTM)* berdasarkan analisis historis harga, kuantitas, dan waktu pembelian suku cadang.
4. Evaluasi kinerja model akan difokuskan pada pengukuran tingkat keakuratan, efisiensi, dan relevansi rekomendasi pembelian suku cadang dalam konteks kebutuhan operasional PLN Nusantara Power. Metrik evaluasi yang digunakan termasuk *Mean Squared Error (MSE)*, *Root Mean Squared Error (RMSE)*, *Mean Absolute Error (MAE)*, dan *Mean Absolute Percentage Error (MAPE)*.
5. Penelitian ini tidak akan mencakup implementasi dan validasi model rekomendasi pembelian suku cadang dalam sistem PLN Nusantara Power. Namun demikian, rekomendasi untuk langkah-langkah implementasi dan validasi lebih lanjut akan diberikan sebagai bagian dari rekomendasi penelitian.

Bab II Tinjauan Pustaka

Referensi penelitian-penelitian yang sudah pernah dilakukan sebelumnya serta pembahasan teori yang mendasari penelitian ini dapat dilihat sebagai berikut.

II.1 Penelitian Sebelumnya

Long Short-Term Memory (LSTM) digunakan untuk memprediksi pengadaan suku cadang dan pemeliharaan, membawa inovasi operasional yang signifikan dalam pembangkitan listrik. LSTM, seperti yang dijelaskan oleh Sherstinsky (2020), adalah bentuk khusus dari *Recurrent Neural Network* (RNN) yang efektif untuk masalah prediksi berbasis *time series*. Metode ini sangat penting dalam memprediksi waktu penggantian suku cadang, sehingga membantu mengurangi *downtime* dan meningkatkan efisiensi operasional.

Menurut Salazar et al. (2022), model ini menunjukkan penerapan model manajemen inventaris yang inovatif yang menggabungkan analisis ABC Multikriteria dengan metode peramalan permintaan yang bertujuan untuk mengoptimalkan stok. Model ini memberikan kontribusi penting terhadap pengelolaan suku cadang yang efisien dengan meningkatkan tingkat layanan dan mengurangi kekurangan stok melalui prediksi yang lebih akurat.

Hal ini sangat relevan di industri pembangkit listrik, di mana ketersediaan suku cadang yang tepat waktu sangat penting untuk menjaga keandalan dan kinerja. Dalam praktik, contoh dari Tang et al. (2023) dan Xie et al. (2022) menyoroti aplikasi teknologi prediktif berbasis LSTM dalam pengaturan industri. Tang et al. mengembangkan sistem untuk pemeliharaan prediktif unit turbin pembangkit listrik menggunakan LSTM untuk deteksi anomali dini, sehingga mengurangi risiko kegagalan yang tidak terduga dan memudahkan pengadaan suku cadang. Sementara itu, Xie et al. mengeksplorasi kerangka kerja berbasis LSTM untuk membangun grafik pengetahuan dari laporan pemeliharaan, memungkinkan dukungan pengambilan keputusan yang didorong data menjadi lebih cepat dan akurat.

Penelitian oleh Jin et al. (2023) menunjukkan bahwa strategi pengendalian prediktif berbasis LSTM-PSO (*Particle Swarm Optimization*) dapat digunakan untuk mengendalikan suhu uap utama di pembangkit listrik. Dengan mengoptimalkan parameter secara *real-time*, strategi ini membantu meminimalkan fluktuasi suhu dan memperpanjang umur komponen, sehingga secara tidak langsung mengurangi kebutuhan penggantian suku cadang yang sering.

Selanjutnya, Azari et al. (2023) menambahkan bahwa penerapan pembelajaran transfer dalam pemeliharaan prediktif, bersama dengan bagian lain dari Industri 4.0, membuka jalan untuk adaptasi algoritma *machine learning* yang lebih efisien dan adaptif yang dapat meningkatkan kesesuaian antara prediksi kegagalan dan pengadaan suku cadang. Pendekatan ini membantu mengatasi beberapa batasan dari algoritma *machine learning* tradisional, memberikan peningkatan yang signifikan dalam presisi dan pengurangan biaya.

Faktanya, baik Chen et al. (2023) maupun Akhtar et al. (2022) menunjukkan implementasi yang sangat spesifik dari teknologi LSTM di area yang sangat teknis dan sensitif, pembangkit listrik tenaga nuklir dan instalasi PV, masing-masing. Chen et al. (2023) mengembangkan model prediksi untuk otomatis selama kondisi abnormal, sementara Akhtar et al. (2022) menggunakan model berbasis LSTM untuk memprediksi daya keluaran dari PV. Keduanya menekankan pentingnya teknologi prediktif dalam mengoptimalkan operasi pembangkit listrik dan pengadaan suku cadang secara efektif.

Terlihat jelas dari berbagai aplikasi dan perkembangan teknologi ini bahwa LSTM tidak hanya mengubah cara industri melakukan pemeliharaan prediktif dan pengadaan suku cadang, tetapi juga menetapkan dasar yang kokoh untuk inovasi lebih lanjut yang akan meningkatkan keandalan dan efisiensi operasional pembangkit listrik.

II.2 Manajemen Rantai Pasok

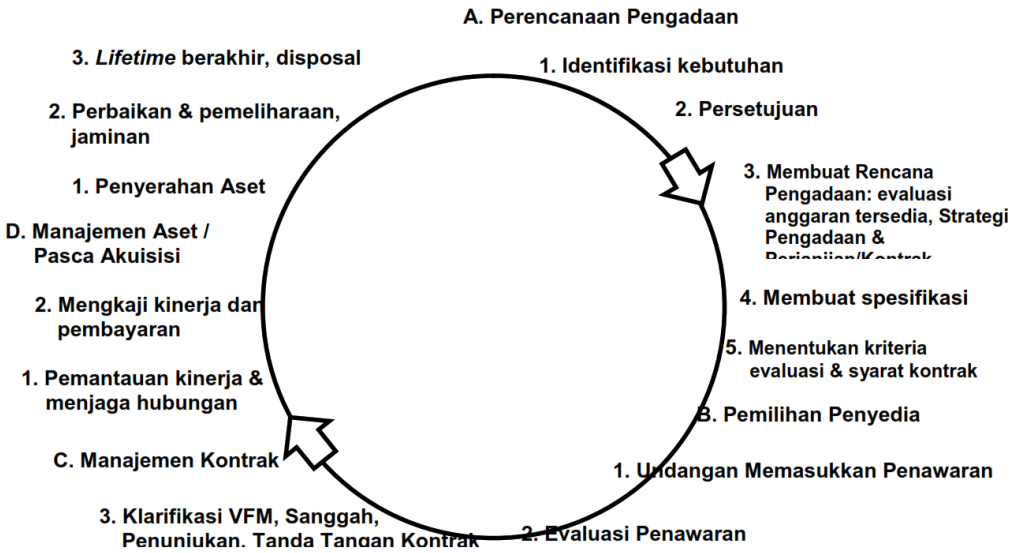

Gambar II.1 Siklus Pengadaan

Manajemen rantai pasok (*Supply Chain Management*, SCM) merupakan kunci penting dalam meningkatkan efisiensi operasional dan keberhasilan perusahaan. SCM di PLN Nusantara Power (PLN NP) difokuskan pada optimalisasi proses pengadaan untuk memastikan ketersediaan suku cadang yang tepat waktu dan efisien, yang sangat krusial untuk operasional pembangkit listrik. PLN NP mengimplementasikan prinsip-prinsip pengadaan yang bertujuan untuk memastikan nilai uang (*value for money*) dan keberlanjutan dalam pengadaan barang dan jasa. Ini termasuk penekanan pada kualitas, kuantitas, waktu, tempat, tujuan sosial ekonomi, dan harga yang kompetitif (Peraturan Menteri BUMN No. PER-05/MBU/2008).

Proses perencanaan pengadaan di PLN NP dibuat setiap tahun berdasarkan Rencana Kerja dan Anggaran Perusahaan (RKAP) melalui konsolidasi di level korporat. Rencana pengadaan di PLN NP menggunakan metode *bottom-up* yang artinya perencanaan diinisiasi oleh usulan unit-unit pembangkit berdasarkan kebutuhan pengadaan di tahun berikutnya, kemudian dari usulan tersebut akan divalidasi dan diverifikasi kembali di level korporat. Kegiatan perencanaan pengadaan di PLN NP juga mencakup penilaian risiko yang menyeluruh, dimana fungsi Manajemen

Risiko dan Kepatuhan berperan dalam mendorong pengelolaan risiko yang efektif pada setiap tahap pengadaan.

Strategi pengadaan di PLN NP melibatkan penilaian menyeluruh dari kebutuhan pengadaan berdasarkan analisis pasar dan portofolio pengadaan. Hal ini termasuk evaluasi dari kemampuan dan kapasitas penyedia, serta riset pasar untuk menyesuaikan strategi pengadaan dengan kondisi pasar yang berubah. Ini membantu dalam menyusun perjanjian dan kontrak yang efektif yang meminimalkan risiko dan meningkatkan efisiensi operasional. Setelah strategi pengadaan ditetapkan, proses selanjutnya adalah implementasi yang meliputi pemilihan penyedia, penandatanganan kontrak, dan pemantauan kinerja penyedia. Proses ini mendukung transparansi dan akuntabilitas dalam pengadaan serta memastikan bahwa semua pihak mematuhi standar yang telah ditetapkan untuk mencapai tujuan organisasi.

Sebagai bagian dari BUMN, PLN NP juga berfokus pada pendayagunaan produk dalam negeri. Hal ini tidak hanya mendukung pertumbuhan ekonomi nasional tetapi juga mengurangi risiko suplai karena ketergantungan pada penyedia internasional bisa diminimalisir. Inisiatif ini juga mencerminkan komitmen perusahaan terhadap pembangunan berkelanjutan dan keberlanjutan operasional (Kepdir No.100.DIR.2017).

II.3 *Machine Learning*

Machine Learning adalah cabang kecerdasan buatan yang fokus pada pengembangan algoritma yang memungkinkan mesin untuk belajar dari data dan juga membuat prediksi atau keputusan berdasarkan data. Algoritma *machine learning* membangun model matematis dari data contoh, yang biasanya disebut dengan data pelatihan (*training data*), untuk melakukan prediksi atau memberi keputusan dari suatu kasus tertentu.

Menurut Lima (2022), *machine learning* dapat didefinisikan sebagai proses menurunkan pengetahuan baru dalam kehidupan sehari-hari dengan cara

memberikan penjelasan yang berulang secara terus menerus. Lima mengusulkan pendekatan baru yang tidak hanya mengandalkan teori pembelajaran statistik tradisional, yang memerlukan asumsi tidak umum tentang peningkatan jumlah set pelatihan yang tak terbatas, namun lebih kepada konsep inferensi yang dikenal dengan *'abduction'*.

Wei (2022) menjelaskan interaksi antara teori informasi dan *machine learning*, papernya memaparkan bagaimana teori informasi telah menginspirasi atau meminjam ide dari metode *machine learning*. Paper ini memberikan tinjauan interaksi tersebut dalam empat area penting *machine learning*: *clustering*, *semi-supervised learning*, *feature selection*, dan *metric learning*.

Konsep utama di dalam *machine learning* adalah sebagai berikut:

1. *Learning Algorithms*. Ini adalah algoritma yang dapat belajar dari data dan dapat membuat prediksi. Contohnya adalah *supervised learning algorithm* seperti regresi linear dan *support vector machine*, dan *unsupervised learning algorithm* seperti pengelompokan k-means (Zhou, Z.-H. (2021). Machine Learning (edisi ke-2). Springer).
2. *Model Training*. Proses ini melibatkan pengembangan model matematika yang menentukan cara yang spesifik dalam penanganan data. Proses pelatihan ini menyesuaikan parameter model untuk mengoptimalkan kriteria tertentu, biasanya akurasi atau rasio kesalahan.
3. *Generalization*. Kemampuan model *machine learning* untuk dapat bekerja dengan baik untuk kumpulan data baru yang belum pernah dilihat sebelumnya, bukan hanya untuk data yang sudah pernah dilatih (Russell, S., & Norvig, P. (2020). Artificial Intelligence: A Modern Approach (edisi ke-4). Prentice Hall).

Metodologi *machine learning* bervariasi tergantung pada jenis input data dan output yang diinginkan:

1. *Supervised Learning*. Metode ini menggunakan data berlabel untuk melatih algoritma/model. Mesin belajar untuk mendapatkan fungsi yang memetakan

input ke output berdasarkan pasangan input-output yang dilatih (Bishop, C. M. (2021). Pattern Recognition and Machine Learning (2nd ed.). Springer).

2. *Unsupervised Learning*. Pada Metode ini, data pelatihan terdiri dari input tanpa diberikan output/respons yang berlabel. Tujuannya adalah untuk memahami struktur dari data, seperti pengelompokan atau reduksi dimensi.
3. *Reinforcement Learning*: Metode ini melibatkan lingkungan serta *reward* agar algoritma dapat mencoba banyak kemungkinan pada lingkungan tertentu untuk mendapatkan *reward/goal* terbaik. Metodologi ini umum terjadi di lingkungan dinamis seperti robotika dan *games* (Lapan, M. (2022). Deep Reinforcement Learning Hands-On (2nd ed.). Packt Publishing).

Penerapan *machine learning* sangat luas cakupannya dan masih terus berkembang hingga saat ini. Beberapa sektor yang menggunakan ML antara lain adalah sektor kesehatan yang menggunakannya untuk diagnosa rekomendasi pengobatan, sektor keuangan yang menggunakannya untuk *fraud detection*, serta sektor kendaraan yang menggunakannya untuk membuat kendaraan berkendara secara otomatis dengan memproses data berjumlah besar yang berada pada sensor-sensor dan kamera yang dipasang pada kendaraan untuk membuat keputusan secara *real-time*.

Meskipun bermanfaat, machine learning memiliki tantangan antara lain adalah privasi data, risiko keamanan, dan masalah etis dan transparansi pengambilan keputusan. Masalah-masalah ini memerlukan penelitian lebih lanjut dan membutuhkan regulasi untuk memastikan bahwa teknologi ML dapat digunakan secara bertanggung jawab.

II.4 Data *Time-series*

Data *time-series* atau deret waktu adalah jenis data yang dapat diukur pada interval waktu yang seragam. Data deret waktu adalah data yang memiliki urutan pengamatan yang diambil secara sekuensial sepanjang waktu. Data deret waktu digunakan di berbagai bidang termasuk ekonomi, keuangan, sains, dan rekayasa untuk menganalisis tren periode, siklus, atau musiman yang mungkin ada dalam data yang diamati.

Pola yang ada pada data deret waktu menurut Hyndman, R. J. (2021) adalah:

1. *Trend*, yaitu pola umum naik ataupun turun dalam rentang waktu yang panjang
2. *Seasonal*, yaitu pola fluktuasi naik atau turun yang disebabkan oleh musim tertentu, bisa dalam rentang waktu harian, mingguan, bulanan, ataupun tahunan.
3. *Cyclical*, yaitu pola data yang menunjukkan kenaikan ataupun penurunan yang tidak dalam frekuensi yang tetap, durasi fluktuasi ini biasanya paling tidak selama 2 tahun.

Masalah umum yang biasanya terjadi pada data deret waktu adalah data kosong atau *Not a Number* (NaN) yang dapat mengganggu analisis dan membuat model prediktif menjadi tidak akurat. Untuk penanganan hal tersebut umumnya dilakukan beberapa metode yaitu:

1. *Forward Filling.* Metode ini menggunakan teknik pengisian nilai NaN dengan nilai observasi terakhir yang diketahui. Misalnya, jika nilai pada waktu ‘t’ hilang, maka akan diisi dengan nilai dari waktu ‘t-1’. Ini sering digunakan ketika data dianggap memiliki kontinuitas antara titik observasi berturut-turut.
2. *Backward Filling.* Berkebalikan dengan *forward filling*, metode ini mengisi nilai NaN dengan nilai observasi yang berikutnya. Jika nilai pada waktu ‘t’ hilang, maka akan diisi dengan nilai dari waktu ‘t+1’. Metode ini bisa berguna ketika nilai yang lebih baru lebih mewakili kondisi yang hilang.
3. Interpolasi Linear. Metode ini mengisi nilai yang hilang dengan menggunakan garis lurus yang menghubungkan dua titik data yang diketahui sebelum dan setelah NaN. Ini adalah pendekatan yang lebih matematis dan sering digunakan ketika perubahan data data yang memiliki sebaran linier.

II.5 *Supervised Learning*

Supervised learning adalah salah satu metode utama dari *machine learning* di mana model dibuat dan dilatih menggunakan dataset yang berlabel. Setiap entri data

dalam dataset ini terdiri dari input dan output label yang sesuai. Tujuan utama dari *supervised learning* adalah untuk membangun sebuah model yang mampu memprediksi label output yang tepat untuk input baru berdasarkan contoh-contoh yang telah dipelajari selama fase pelatihan.

Ada banyak metode yang digunakan untuk melakukan *supervised learning*, setiap metode punya kelebihan dan kekurangannya masing-masing. Berikut adalah beberapa metode *supervised learning*:

1. Regresi Linear dan Regresi Logistik. Regresi linear digunakan pada saat data target (*output*) bersifat kuantitatif atau kontinu, sedangkan regresi logistik digunakan pada saat data target bersifat *categorical* seperti 0/1, ya/tidak.
2. *Support Vector Machine* (SVM) adalah metode yang sangat baik digunakan untuk kasus-kasus data yang berdimensi tinggi.
3. *Decision Tree* (DT) dan *Random Forest* (RF). DT adalah metode untuk membuat model dalam bentuk struktur pohon. Metode ini bekerja dengan cara membagi dataset menjadi bagian-bagian kecil berdasarkan fitur (variabel) tertentu, sehingga dataset yang kompleks akan dipecah menjadi subset data yang lebih sederhana. RF adalah metode pembelajaran secara acak yang terdiri dari banyak pohon keputusan. Ini mengurangi risiko overfitting yang sering terjadi dalam model DT tunggal dengan cara menggabungkan hasil dari banyak pohon untuk membuat keputusan akhir yang lebih stabil dan akurat.
4. Jaringan Saraf Tiruan (*Neural Network*). Model ini meniru cara kerja otak manusia dan sangat efektif dalam mengidentifikasi pola kompleks dalam data. Pengembangan terbaru dalam neural networks, seperti deep learning, telah sangat mempengaruhi kemampuan model-model *supervised learning* saat ini (LeCun, Y. (2015). Deep Learning).

Perkembangan metode *supervised learning* dapat dilihat pada kemajuan signifikan dalam teknologi *deep learning*. Metode ini menggunakan jaringan saraf tiruan yang mendalam untuk mengidentifikasi pola kompleks dan perbedaan yang kecil dalam

data yang besar dan tidak terstruktur, seperti gambar, teks, dan audio. Kemampuan untuk memproses dan mempelajari jenis data ini telah mengubah banyak sektor, termasuk kesehatan, keuangan, dan pengenalan suara.

Selain itu, Teknik *transfer learning* (pembelajaran transfer) telah menjadi sangat populer. Melalui pembelajaran transfer, model yang telah dilatih untuk satu tugas dapat disesuaikan untuk tugas lain dengan sedikit modifikasi, mengurangi waktu dan sumber daya yang diperlukan untuk pengembangan model. Teknik ini sangat efektif dalam meningkatkan kinerja model pada tugas-tugas dengan dataset yang terbatas.

Automated Machine Learning (AutoML) adalah penerapan otomatisasi dalam desain model *machine learning*. AutoML memungkinkan pengguna tanpa latar belakang teknis mendalam untuk dapat merancang, melatih, dan menerapkan model *machine learning* yang efektif, membuka pintu bagi lebih banyak penerapan aplikatif dan inovasi dalam *supervised learning*. Teknologi ini tidak hanya meningkatkan aksesibilitas dan efisiensi tetapi juga membantu dalam mengeksplorasi kompleksitas model yang optimal dengan cepat.

II.6 *Artificial Neural Network* (ANN)

Jaringan Saraf Tiruan (*Artificial Neural Network*, ANN) adalah sistem komputasi yang terinspirasi oleh jaringan saraf biologis yang membentuk otak manusia. ANN terdiri dari node atau neuron yang terhubung, yang menerima input dan menghasilkan output berdasarkan input tersebut. Setiap koneksinya memiliki bobot yang menyesuaikan selama proses pembelajaran, yang sangat memengaruhi hasil yang dihasilkan oleh jaringan. Arsitektur sederhana pada ANN adalah *input layer*, *hidden layer* hingga *output layer*.

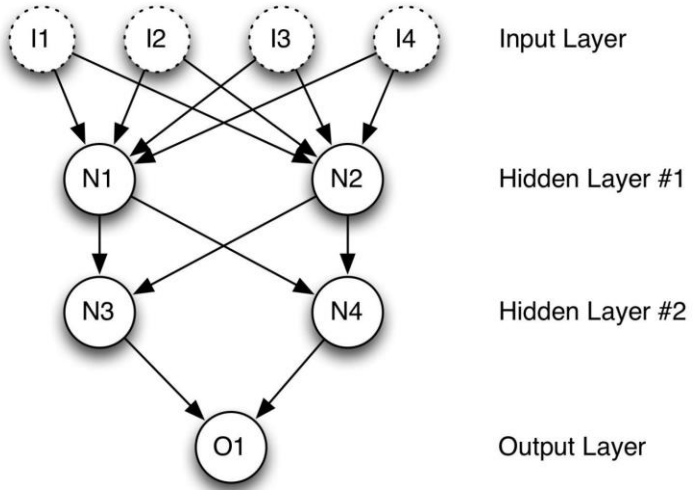

Gambar II.2 Arsitektur ANN

Metode yang digunakan pada ANN umumnya adalah:

1. *Feedforward.* Metode ANN paling sederhana, di mana informasi hanya bergerak ke depan, dari input node kemudian maju melalui hidden layers, hingga sampai ke output node. Tidak ada siklus atau loop dalam metode ini.
2. *Backpropagation.* Metode ini yang digunakan untuk melatih ANN, dimana gradien dari fungsi kehilangan (*loss function*) dikalkulasi dan didistribusikan kembali ke jaringan. Tujuannya adalah untuk mengoptimalkan bobot dalam jaringan agar error antara output prediksi dan output aktual seminimal mungkin.

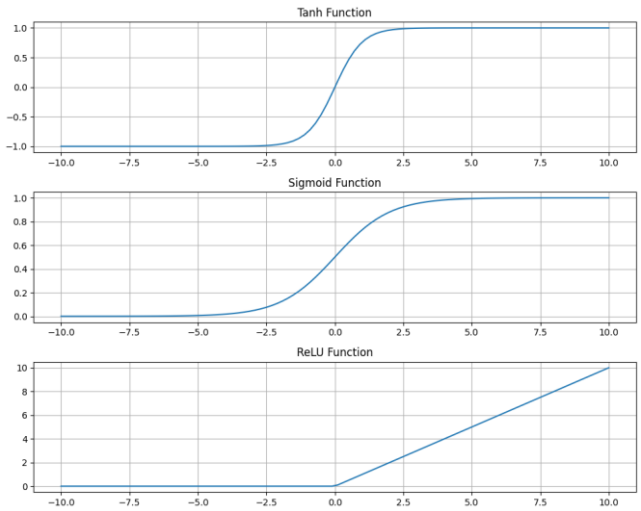

Gambar II.3 Fungsi Aktivasi

Ada juga hal yang cukup penting pada ANN yang disebut dengan Fungsi aktivasi. Fungsi aktivasi adalah komponen krusial dalam jaringan saraf tiruan yang memutuskan apakah neuron tertentu harus diaktifkan atau tidak. Fungsi ini membantu menentukan output dari setiap neuron melalui transformasi nonlinear dari input yang diterima. Fungsi aktivasi memainkan peran penting dalam kemampuan jaringan saraf untuk mempelajari dan membuat representasi yang kompleks. Beberapa fungsi aktivasi yang paling umum adalah:

1. Sigmoid. Fungsi ini menghasilkan output antara nilai 0 dan 1. Fungsi ini biasa digunakan untuk model yang memprediksi probabilitas sebagai output.
2. ReLU (*Rectified Linear Unit*). Fungsi ini paling sering digunakan karena efisien dan efektif, memberikan output nilai 0 untuk nilai input negatif dan output linear untuk nilai input positif (Goodfellow (2022). Deep Learning).
3. Tanh (*Hyperbolic Tangent*). Fungsi ini memberikan output antara -1 sampai dengan 1 sehingga memberikan distribusi output yang lebih terpusat daripada sigmoid.

Perkembangan ANN terus mengalami kemajuan yang signifikan, terutama dengan diperkenalkannya teknik-teknik deep learning yang memperluas batas-batas kemampuan ANN. Deep learning, melalui arsitektur seperti Convolutional Neural Networks (CNN) dan Recurrent Neural Networks (RNN), telah memungkinkan peningkatan dramatis dalam pemrosesan dan analisis data yang kompleks dan besar. CNN telah revolusioner dalam pengolahan gambar dan video, sedangkan RNN telah membuat ide dan solusi baru di dalam bidang *natural language processing* (NLP) dan pengolahan data *time-series*. Teknik-teknik ini telah menunjukkan efektivitas yang luar biasa dalam berbagai aplikasi, dari pengenalan wajah dan analisis sentimen hingga pengendalian robot.

II.7 *Recurrent Neural Network* (RNN)

RNN adalah jenis jaringan saraf tiruan yang dirancang untuk mengenali pola dalam data sekuensial seperti teks, suara, atau *time-series*. RNN mampu menggunakan informasi dari output sebelumnya sebagai input untuk pengambilan keputusan saat

ini, sehingga membuat jaringan untuk dapat "mengingat" informasi sebelumnya di dalam prosesnya. Hal ini membuat RNN sangat cocok untuk tugas-tugas seperti NLP atau analisis *time-series*, di mana hubungan sekuensial antar data penting untuk prediksi yang akurat.

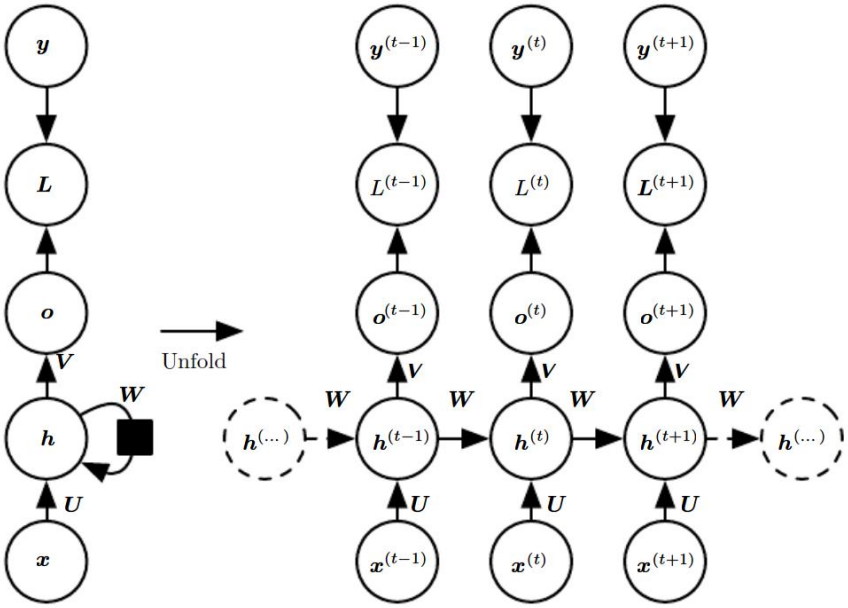

Gambar II.4 General RNN

Pada dasarnya, RNN memiliki struktur yang sama dengan ANN yaitu *input layer*, *hidden layer*, dan juga *output layer*. Proses pelatihannya pun cenderung sama seperti proses pelatihan ANN sederhana. Diawali dengan memproses data secara *forward pass* hingga mendapatkan *output* prediksi, namun perbedaannya adalah prosesnya bergerak pada setiap elemen/input (x) secara berurut satu demi satu, menyimpan representasi dari informasi yang sudah diproses sebelumnya dalam apa yang disebut sebagai *hidden state* (h). Setelah hidden state dihitung maka akan dilanjutkan untuk menghitung *output* prediksinya (o). Kemudian output prediksi akan dibandingkan dengan output aktual (y) dengan *loss function* (L). Kemudian nilai dari *loss function* akan dilakukan *backpropagation through time* (BPTT) untuk menghitung deviasi error pada setiap langkah waktu di dalam jaringan. Setelah BPTT dilakukan maka dilakukan pembaruan bobot dan juga biasnya dengan metode *Stochastic Gradient Descent* (SGD).

Jika digambarkan kembali arsitektur RNN dengan ilustrasi yang lebih sederhana akan tampak seperti gambar berikut:

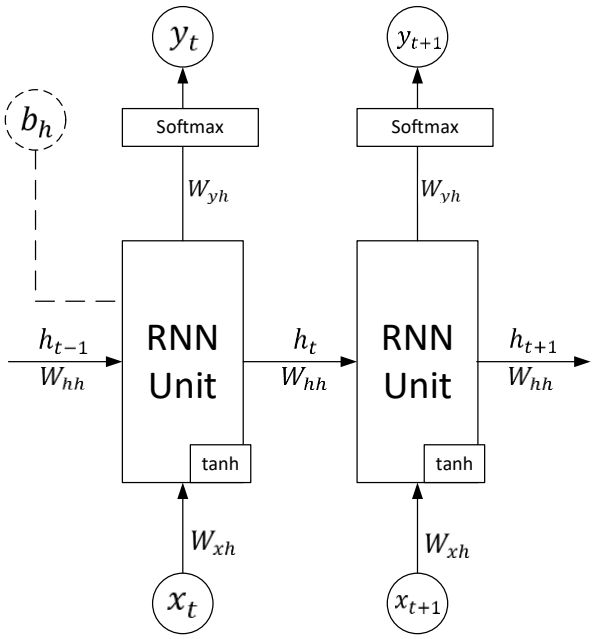

Gambar II.5 Arsitektur RNN

Rumus:

1. Pembaruan Hidden State:

$$h_t = \tanh(\, W_{hh} \cdot h_{t-1} + W_{xh} \cdot x_t + b_h \,) \qquad (1)$$

   Dimana:

   - h_t adalah hidden state pada waktu t.
   - h_{t-1} adalah hidden state dari waktu sebelumnya.
   - x_t adalah input pada waktu t.
   - W_{hh} adalah bobot untuk hidden state sebelumnya.
   - W_{xh} adalah bobot untuk input.
   - b_h adalah bias untuk hidden state.
   - tanh adalah fungsi aktivasi yang membantu menormalkan hasil, nilainya antara -1 dan 1.

2. Keluaran Output:

$$y_t = softmax(W_{yh} \cdot h_t + b_h) \quad (2)$$

Dimana:

- y_t adalah ouput pada waktu t.
- W_{yh} adalah bobot untuk hidden state ke output.
- h_t adalah hidden state pada waktu t
- b_h adalah bias untuk output
- Softmax adalah fungsi aktivasi untuk melakukan normalisasi pada nilai eksponensial

Namun ada 2 kelemahan khusus yang rentan dialami oleh RNN yaitu *vanishing* dan *exploding gradient*. *Vanishing gradient* terjadi ketika gradien yang digunakan dalam proses backpropagation menjadi sangat kecil, efektifnya mendekati nol, sehingga membuat bobot dalam jaringan tidak lagi berubah secara signifikan. Ini menghentikan proses pembelajaran atau membuatnya sangat lambat. Dalam RNN, masalah ini sering terjadi karena penggandaan berulang dari gradien yang melalui fungsi aktivasi seperti sigmoid atau tanh, yang memiliki gradien sangat kecil di sebagian besar area mereka. Sebagai hasilnya, jika RNN harus belajar ketergantungan jangka panjang dalam data, kemampuan untuk mempertahankan informasi relevan menjadi terbatas, dan pembelajaran ketergantungan ini menjadi tidak efektif.

Exploding gradient adalah kebalikan dari *vanishing gradient*. Dalam kasus ini, gradien dalam proses pelatihan menjadi sangat besar sehingga menyebabkan pembaharuan bobot yang ekstrem. Hal ini bisa menyebabkan model menjadi tidak stabil. Nilai bobot bisa menjadi sangat besar sehingga model tidak dapat konvergen atau bahkan menghasilkan nilai NaN untuk output. Exploding gradient biasanya terjadi ketika produk dari gradien berulang-ulang menghasilkan nilai yang besar, hal ini sering kali terjadi dalam RNN dengan ketergantungan jangka panjang yang kuat atau dengan data yang memiliki variasi besar. Permasalahan yang terjadi pada ini melahirkan metode baru pengembangan RNN yaitu *Long Short-Time Memory* (LSTM).

II.8 *Long Short-Time Memory* (LSTM)

LSTM adalah jenis arsitektur jaringan saraf tiruan yang dikembangkan untuk mengatasi kelemahan yang terdapat pada RNN, terutama masalah *vanishing* dan *exploding gradient*. LSTM dirancang oleh Sepp Hochreiter dan Jürgen Schmidhuber pada tahun 1997 dan telah menjadi alat penting dalam *deep learning* untuk menangani data sekuensial. LSTM memungkinkan jaringan untuk mempelajari ketergantungan jangka panjang dengan lebih efektif.

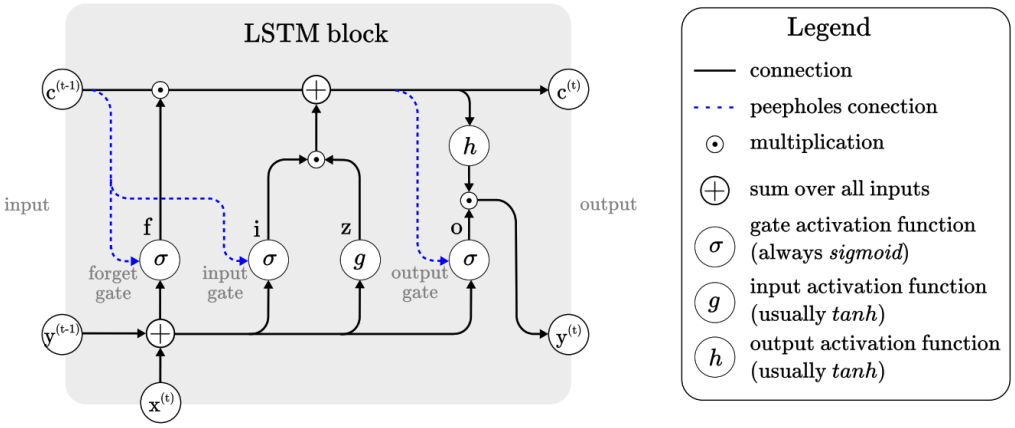

Gambar II.6 Arsitektur LSTM

Secara sederhana LSTM memiliki 2 buah *sequence* proses yaitu *Long Term Memory* atau terkadang disebut juga dengan *cell state* (c) dan juga *Short Term Memory* yang akan memberikan *block output* (y). *Cell state* ini akan menyimpan informasi yang relevan selama proses pengolahan data. Ini memungkinkan informasi dapat diakses lebih mudah pada tahap-tahap selanjutnya pada *sequence* proses. LSTM memiliki 3 jenis gerbang (*gates):*

1. *Input Gate,* yang bertugas untuk menentukan nilai mana dari masukan yang harus digunakan untuk memodifikasi memori. Fungsi aktivasi yang digunakan adalah fungsi sigmoid yang menentukan nilai mana yang akan dilewati serta fungsi tanh yang memberikan bobot kepada nilai-nilai tersebut.

   Blok input pada LSTM dapat dirumuskan sebagai berikut:

$$z^{(t)} = g(W_z \cdot x^{(t)} + R_z \cdot y^{(t-1)} + b_z\ ) \qquad (3)$$

Dimana:

- $z^{(t)}$ adalah blok input.
- W_z adalah bobot pada input $x^{(t)}$.
- $x^{(t)}$ adalah input saat ini.
- R_z adalah bobot pada output sebelumnya $y^{(t-1)}$.
- $y^{(t-1)}$ adalah output sebelumnya.
- b_z adalah variabel bias.
- g adalah fungsi aktivasi tanh.

Pembaharuan nilai input pada LSTM dapat dirumuskan sebagai berikut:

$$i^{(t)} = \sigma\left(W_i \cdot x^{(t)} + R_i \cdot y^{(t-1)} + p_i \cdot c^{(t-1)} + b_i\right) \quad (4)$$

Dimana:

- $i^{(t)}$ adalah input pembaharuan.
- W_i adalah bobot pada input $x^{(t)}$.
- $x^{(t)}$ adalah input saat ini.
- R_i adalah bobot pada output sebelumnya $y^{(t-1)}$.
- $y^{(t-1)}$ adalah output sebelumnya.
- p_i adalah bobot pada *cell* sebelumnya $c^{(t-1)}$.
- $c^{(t-1)}$ adalah nilai *cell* sebelumnya.
- b_i adalah variabel bias.
- σ adalah fungsi aktivasi sigmoid.

2. *Forget Gate*, yang bertugas untuk menentukan informasi apa saja yang harus dibuang ataupun disimpan dalam blok. Ini juga diputuskan oleh fungsi sigmoid.

   Formula perhitungan pada *forget gate* dapat dirumuskan sebagai berikut:

$$f^{(t)} = \sigma\left(W_f \cdot x^{(t)} + R_f \cdot y^{(t-1)} + p_f \cdot c^{(t-1)} + b_f\right) \quad (5)$$

Dimana:

- $f^{(t)}$ adalah nilai *forget gate*.
- W_f adalah bobot pada input $x^{(t)}$.
- $x^{(t)}$ adalah input saat ini.
- R_f adalah bobot pada output sebelumnya $y^{(t-1)}$.
- $y^{(t-1)}$ adalah output sebelumnya.
- p_f adalah bobot pada *cell* sebelumnya $c^{(t-1)}$.
- $c^{(t-1)}$ adalah nilai *cell* sebelumnya.
- b_f adalah variabel bias.
- σ adalah fungsi aktivasi sigmoid.

Untuk menghitung nilai *cell* dapat dirumuskan sebagai berikut:

$$c^{(t)} = z^{(t)} \cdot i^{(t)} + c^{(t-1)} \cdot f^{(t)} \tag{6}$$

Dimana:

- $c^{(t)}$ adalah nilai *cell*.
- $z^{(t)}$ adalah blok input.
- $i^{(t)}$ adalah nilai input.
- $f^{(t)}$ adalah nilai *forget gate*.

3. *Ouput Gate*, bertugas untuk menentukan apa yang akan menjadi *hidden state* berikutnya. *Hidden state* mengandung informasi tentang input sebelumnya. Informasi ini akan difilter oleh fungsi sigmoid, dan kemudian hasilnya akan dikalikan dengan hasil dari fungsi tanh yang ada pada *cell state*.

   Formula perhitungan pada *output gate* dapat dirumuskan sebagai berikut:

$$o^{(t)} = \sigma\left(W_o \cdot x^{(t)} + R_o \cdot y^{(t-1)} + p_o \cdot c^{(t)} + b_o\right) \tag{7}$$

Dimana:

- $o^{(t)}$ adalah nilai *output gate*.
- W_o adalah bobot pada input $x^{(t)}$.
- $x^{(t)}$ adalah input saat ini.
- R_o adalah bobot pada output sebelumnya $y^{(t-1)}$.
- $y^{(t-1)}$ adalah output sebelumnya.
- p_o adalah bobot pada *cell* saat ini $c^{(t)}$.
- $c^{(t)}$ adalah nilai *cell* saat ini.
- b_o adalah variabel bias.
- σ adalah fungsi aktivasi sigmoid.

Blok output dapat dirumuskan sebagai berikut:

$$y^{(t)} = g(c^{(t)}) \cdot o^{(t)} \tag{8}$$

Dimana:

- $y^{(t)}$ adalah blok output.
- $c^{(t)}$ adalah nilai *cell* saat ini.
- g adalah fungsi aktivasi tanh.
- $o^{(t)}$ adalah nilai *output gate.*

II.9 *Gated Recurrent Unit* (GRU)

Sama seperti LSTM, Gated Recurrent Unit (GRU) juga adalah salah satu varian dari RNN yang dikembangkan untuk mengatasi masalah *vanishing gradient* yang sering terjadi pada RNN tradisional. GRU diperkenalkan oleh Cho et al. pada tahun 2014. GRU dirancang untuk lebih efisien pada proses komputasinya serta lebih mudah untuk dioptimalkan dibandingkan dengan LSTM karena memiliki struktur yang lebih sederhana. GRU menyederhanakan struktur LSTM dengan menggabungkan *forget gate* dan *input gate* menjadi satu gerbang tunggal, yang disebut sebagai gerbang pembaruan (*update gate*). Selain itu, GRU juga memperkenalkan *reset gate*.

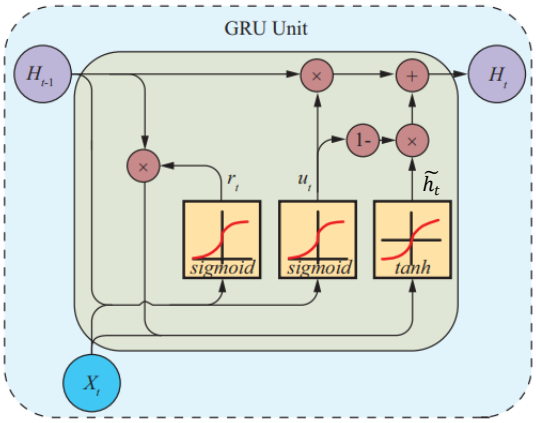

Berikut adalah dua komponen utama dalam GRU:

1. *Update Gate* (u), yg menentukan seberapa banyak informasi dari state sebelumnya yang harus dibawa ke state selanjutnya. Gerbang ini berfungsi mirip dengan kombinasi gerbang lupa dan input pada LSTM, membantu model memutuskan informasi mana yang cukup penting untuk diingat dan informasi mana yang harus dilupakan. Rumus pada *update gate* dapat dilihat sebagai berikut:

$$u_t = \sigma(W_{xu} \cdot X_t + W_{hu} \cdot H_{t-1} + b_u) \tag{9}$$

   Dimana:

   - u_t adalah *output update gate*.
   - W_{xu} adalah bobot pada input X_t.
   - X_t adalah input saat ini.
   - W_{hu} adalah bobot pada output sebelumnya H_{t-1}.
   - H_{t-1} adalah output sebelumnya.
   - b_u adalah variabel bias.
   - σ adalah fungsi aktivasi sigmoid.

2. *Reset Gate* (r), yg digunakan untuk menentukan seberapa banyak informasi masa lalu yang akan digunakan dalam membentuk kandidat konten memori baru. Gerbang ini memungkinkan model untuk menghapus informasi yang tidak relevan sebelum menggabungkan informasi baru, sehingga memungkinkan GRU menjadi efektif dalam memodelkan hubungan dengan

jangkauan waktu yang bervariasi. Rumus pada *reset gate* dapat dilihat sebagai berikut:

$$r_t = \sigma(W_{xr} \cdot X_t + W_{hr} \cdot H_{t-1} + b_r) \quad (10)$$

Dimana:

- r_t adalah *output reset gate*.
- W_{xr} adalah bobot pada input X_t.
- X_t adalah input saat ini.
- W_{hr} adalah bobot pada output sebelumnya H_{t-1}.
- H_{t-1} adalah output sebelumnya.
- b_r adalah variabel bias.
- σ adalah fungsi aktivasi sigmoid.

Untuk menentukan nilai output H_t, harus menghitung nilai $\tilde{h}_t$ terlebih dahulu, rumusnya adalah sebagai berikut:

$$\tilde{h}_t = g(W_{xh} \cdot X_t + W_{hh}\,(r_t \cdot H_{t-1}) + b_h) \quad (11)$$

Dimana:

- $\tilde{h}_t$ adalah *output fungsi tanh*.
- W_{xh} adalah bobot pada input X_t.
- X_t adalah input saat ini.
- W_{hh} adalah bobot pada output sebelumnya H_{t-1} dikalikan dengan output *reset gate* r_t.
- r_t adalah *output reset gate*
- H_{t-1} adalah output sebelumnya.
- b_h adalah variabel bias.
- g adalah fungsi aktivasi tanh.

Setelah itu H_t dapat dihitung dengan rumus berikut:

$$H_t = u_t \cdot H_{t-1} + (1 - u_t) \cdot \tilde{h}_t \quad (11)$$

Dimana:

- H_t adalah *output* GRU unit.
- u_t adalah *output update gate*.
- H_{t-1} adalah output sebelumnya.
- $\tilde{h}_t$ adalah *output fungsi tanh*.

II.9 Metrik Evaluasi Model

Metrik evaluasi model adalah alat penting yang digunakan untuk mengukur kinerja model *machine learning*. Metrik ini memberikan gambaran yang penting mengenai seberapa baik model memprediksi data dan digunakan untuk menyempurnakan model selama proses pelatihan dan validasi. Biasanya, metrik yang dipilih tergantung pada jenis masalah yang ditemui seperti klasifikasi, regresi, clustering, dll.

Berikut adalah beberapa metrik untuk model regresi:

1. *Mean Square Error* (MSE). Metrik ini mengukur rata-rata kuadrat kesalahan antara nilai yang diprediksi oleh model dan nilai aktual. MSE adalah metrik yang sangat populer karena memperhitungkan kuadrat kesalahan, yang memberikan bobot lebih pada kesalahan yang lebih besar, sehingga sangat berguna dalam banyak kasus dimana kesalahan besar tidak diinginkan.

   Rumus:

   $$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - y'_i)^2 \quad (12)$$

   Dimana: y_i adalah nilai sebenernya; dan y'_i adalah nilai prediksi.

2. *Root Mean Squared Error* (RMSE). Metrik ini adalah akar kuadrat dari MSE dan memberikan estimasi kesalahan model dalam satuan yang sama dengan target. RMSE lebih sensitif terhadap kesalahan prediksi yang besar karena mengambil akar kuadrat dari MSE.

Rumus:

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - y'_i)^2} \quad (13)$$

Dimana: y_i adalah nilai sebenernya; dan y'_i adalah nilai prediksi.

3. *Mean Absolute Error* (MAE). Metrik ini mengukur rata-rata kesalahan absolut antara prediksi dan nilai aktual. Metrik ini memberi gambaran yang lebih intuitif tentang kesalahan rata-rata karena tidak mengkuadratkan kesalahan sehingga kurang memberikan bobot bagi nilai outlier dibandingkan dengan MSE atau RMSE.

   Rumus:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}\left|y_i - y'_i\right| \quad (14)$$

   Dimana: y_i adalah nilai sebenernya; dan y'_i adalah nilai prediksi.

4. *Mean Persentage Absolute Error* (MAPE). Metrik ini mengukur kesalahan sebagai persentase dan sering digunakan untuk membandingkan akurasi pada model dengan skala yang sama. Metrik ini sangat berguna jika ingin memberikan gambaran kesalahan dalam bentuk persentase yang mudah dipahami bagi orang yang tidak tahu akan konteks data tersebut.

   Rumus:

$$MAPE = \frac{100\%}{n}\sum_{i=1}^{n}\left|\frac{y_i - y'_i}{y_i}\right| \quad (15)$$

   Dimana: y_i adalah nilai sebenernya; dan y'_i adalah nilai prediksi.

Pemilihan metrik yang tepat sangat penting untuk validasi model yang akurat. Dalam beberapa tahun terakhir, penelitian telah difokuskan pada pengembangan metrik yang lebih robust terhadap outlier, dan adaptif terhadap berbagai jenis

distribusi data dan skenario aplikasi. Misalnya, modifikasi dari MAPE dan MAE telah diusulkan untuk meningkatkan ketahanan mereka terhadap data dengan banyak nilai nol atau outlier. Metrik evaluasi tidak hanya penting untuk menilai kinerja model saat ini tetapi juga untuk mengarahkan proses pelatihan dan penyesuaian model.

Bab III Metodologi Penelitian

Secara garis besar, metodologi yang dilakukan pada penelitian ini dapat dilihat pada bagan berikut.

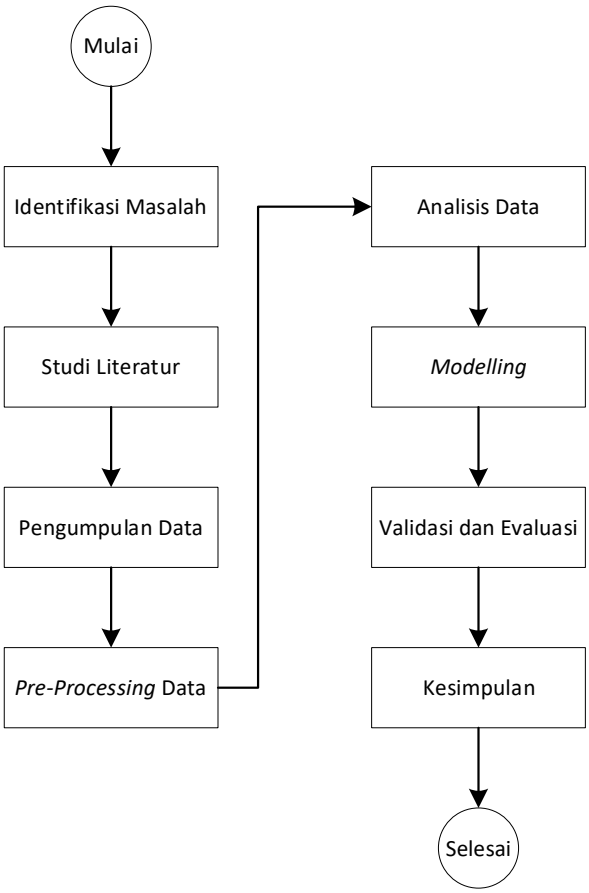

Gambar III.1 Flowchart Metodologi Penelitian

III.1 Identifikasi Masalah

Bagian ini bertujuan untuk mengidentifikasi masalah yang dihadapi dalam pengadaan suku cadang di PLN Nusantara Power (PLN NP). Sebagai perusahaan yang bertanggung jawab atas pengoperasian dan pemeliharaan pembangkit listrik di seluruh nusantara, PLN NP dihadapkan pada tantangan kompleks dalam memastikan ketersediaan suku cadang yang tepat waktu dan efisien. Masalah utama antara lain adalah keterlambatan dalam pengadaan suku cadang serta ketidakpastian dalam memprediksi kebutuhan suku cadang di masa depan. Keterlambatan dalam pengadaan suku cadang dapat mengganggu operasi pembangkit listrik,

mengakibatkan pemadaman listrik (*trip*) atau kapasitas yang berkurang (*derating*), sementara ketidakpastian dalam prediksi kebutuhan suku cadang menyebabkan pembelian yang tidak efisien dan penumpukan yang tidak perlu. Dalam konteks ini, penelitian ini bertujuan untuk mengembangkan model prediktif berbasis LSTM untuk mengatasi tantangan ini dan meningkatkan efisiensi dalam pengadaan suku cadang di PLN NP.

III.2 Studi Literatur

Studi literatur yang dilakukan memberikan wawasan mendalam tentang pendekatan yang telah diambil dalam penelitian. Studi ini mencakup terkait penelitian prediksi pengadaan atau kerusakan di dunia pengadaan, konsep pengadaan suku cadang secara umum pada PLN NP, serta teknik-teknik machine learning hingga LSTM. Dengan mempelajari penelitian sebelumnya, teori-teori serta metode-metode apa saja yang berkaitan dengan penelitian ini diharapkan proses penelitian akan berjalan tepat sasaran sesuai dengan tujuan penelitian.

III.3 Pengumpulan Data

Pengumpulan data merupakan tahap krusial dalam pengembangan model prediktif untuk pengadaan suku cadang di PLN Nusantara Power. Data yang diperlukan mencakup riwayat pembelian suku cadang, termasuk informasi tentang jenis suku cadang, jumlah yang dibeli, tanggal pembelian, dan harga. Data tambahan yang mungkin diperlukan adalah informasi tentang detil inventory itu sendiri, seperti data stockcode, nama suku cadang, spek, dll. Data ini dapat diperoleh dari sistem *Enterprise Asset Management* (EAM) PLN NP. Proses pengumpulan data akan dilakukan dengan memastikan keakuratan, kebersihan, dan kelengkapan data, serta memperhatikan kebijakan privasi dan keamanan data yang berlaku. Berikut adalah cuplikan data yang digunakan dalam penelitian ini:

PREQ_STK_CODE	STOCK_T	STOCK_SECTIONX3	UNIT_OI	PO_ITEN	PO_NO	CURR_N	CURR_N	GROSS_I	CURR_Q	CURR_Q	DSTRCT_	DUE_SITE_DATE	ONST_RCPT_DATE	ONST_R	ORDER_DATE
000000034	E	C	M	1	GF1858	246000	246000	246000	250	250	SGRK	20160218	20160127	1858.01.16	20151120
000000067	E	C	EA	1	GD1380	390000	390000	390000	3	3	SGRK	20131204	20131212	G380.12.13	20130905
000000075	E	C	EA	1	GD0808	700000	700000	700000	4	4	SGRK	20130705	20130708	G808.7.13	20130605
000000083	E	C	EA	2	GD1380	530000	530000	530000	3	3	SGRK	20131204	20131212	G380.12.13	20130905
000000109	E	C	EA	18	GF2024	11990000	11990000	11990000	1	1	SGRK	20160317	20160405	2024.4.16	20151222
000000117	E	B	EA	4	GF0686	650000	650000	650000	2	2	SGRK	20150629	20150909	686.9.15	20150429
000000117	E	B	EA	1	GH0001	650000	650000	650000	4	4	SGRK	20170403	20170308	0001.03.17	20170103
000000117	E	B	EA	1	GG1723	650000	650000	650000	2	2	SGRK	20161206	20161107	1723.11.16	20161025
000000117	E	B	EA	1	GC1149	650000	650000	650000	3	3	SGRK	20120824	20120829	G149.8.12	20120723
000000117	E	B	EA	2	GF0208	650000	650000	650000	2	2	SGRK	20150314	20150226	208.2.15	20150212
000000117	E	B	EA	2	GF1992	650000	650000	650000	2	2	SGRK	20160114	20160114	1992.01.16	20151217
000000133	I	C	EA	1	GG0591	4975000	4975000	4975000	2	2	SGRK	20160725	20160623	591.6.16	20160425
000000133	I	C	EA	1	GG0503	4750000	4750000	4750000	2	2	SGRK	20170117	20160623	503.6.16	20160407
000000232	M	C	EA	5	GE0346	350000	350000	350000	6	6	SGRK	20140515	20140506	0346.5.14	20140401
000000232	M	C	EA	1	GH2486	425000	425000	425000	8	8	SGRK	20180122	20180124	2486.01.18	20171222
000000232	M	C	EA	1	GF1277	375000	375000	375000	4	4	SGRK	20151002	20150916	1277.09.15	20150818
000000232	M	C	EA	1	GG0057	375000	375000	375000	8	8	SGRK	20160215	20160203	057.2.16	20160113
000000232	M	C	EA	1	GF1909	375000	375000	375000	4	4	SGRK	20160118	20151222	1909.12.15	20151202
000000232	M	C	EA	1	GG0714	375000	375000	375000	4	4	SGRK	20160704	20160610	714.06.16	20160517
000000323	I	C	EA	1	GG2092	1250000	1250000	1250000	2	2	SGRK	20170323	20170316	2092.03.17	20161223
000000331	I	C	EA	1	GH2457	2350000	2350000	2350000	1	1	SGRK	20180118	20180115	2457.01.18	20171219
000000331	I	C	EA	1	GH2436	2350000	2350000	2350000	1	1	SGRK	20180119	20180115	2436.01.18	20171219
000000364	E	C	M	1	GH2273	91670	91670	91670	1200	1200	SGRK	20171220	20171211	2273.12.17	20171120
000000430	E	C	EA	1	GD1754	45600	45600	45600	100	100	SGRK	20131205	20131210	G754.12.13	20131115
000000448	E	C	EA	1	GE0457	500000	500000	500000	10	10	SGRK	20140820	20140517	0457.5.14	20140401

Gambar III.2 Cuplikan Data

Data yang digunakan adalah data *Purchase Order* sejak tanggal 1 Januari 2012 hingga tanggal 31 Desember 2023. Data yang dikumpulkan sejumlah 126.869 baris. Data tersebut mewakili data suku cadang-suku cadang dengan berbagai macam pola pembelian. Ada 19 fitur yang diambil untuk dilakukan pemprosan selanjutnya. Untuk detil fitur-fitur atau *attribute-attribute* data tersebut dapat dilihat pada tabel berikut:

Tabel III.1 Fitur-fitur Data

NO	NAMA	KETERANGAN
1	PREQ_STK_CODE	Kode stok untuk setiap suku cadang
2	ITEM_NAME	Nama suku cadang
3	STK_DESC	Detil spesifikasi suku cadang
4	STOCK_TYPE	Jenis suku cadang
5	STOCK_SECTIONX3	Kategori *criticallity* suku cadang
6	UNIT_OF_ISSUE	Satuan dari suku cadang
7	PO_ITEM_NO	Urutan suku cadang di dalam PO
8	PO_NO	Nomor *Purchase Order*
9	CURR_NET_PR_P	Harga bersih pembelian suku cadang
10	GROSS_PRICE_P	Harga kotor pembelian suku cadang
11	CURR_QTY_P	Jumlah suku cadang yang dibeli dalam 1 PO
12	DSTRCT_CODE	Unit pembangkit yang melakukan PO
13	DUE_SITE_DATE	Tanggal penerimaan sesuai kontrak
14	ONST_RCPT_DATE	Tanggal penerimaan realisasi
15	ONST_RCPT_REF	Kode bukti penerimaan realisasi

NO	NAMA	KETERANGAN
16	ORDER_DATE	Tanggal *Purchase Order*
17	CREATION_DATE	Tanggal penginputan PO pada sistem
18	COMPLETED_DATE	Tanggal penyelesaian PO pada sistem
19	SUPPLIER_NO	Kode Penyedia suku cadang

III.4 *Pre-Processing* Data

Setelah data suku cadang dikumpulkan, langkah selanjutnya adalah melakukan *pre-processing* data untuk mempersiapkannya untuk analisis lebih lanjut. Proses *pre-processing* ini melibatkan beberapa tahap, termasuk pembersihan data untuk mengidentifikasi dan menangani nilai yang hilang atau tidak valid, penambahan fitur yang diolah dari fitur-fitur yang ada, normalisasi data untuk menyesuaikan rentang nilai antara fitur yang berbeda, dan transformasi data untuk mengubahnya menjadi format yang lebih sesuai untuk pemodelan prediktif. Selain itu, dapat dilakukan pemilihan fitur untuk menentukan fitur-fitur yang paling relevan dan berdampak dalam memprediksi kebutuhan suku cadang di masa depan. Langkah-langkah ini penting untuk memastikan kualitas dan kecocokan data sebelum diinput ke dalam model prediktif, sehingga hasil analisis yang dihasilkan lebih akurat dan juga andal.

III.5 Analisis Data

Analisis data merupakan tahap penting dalam pengembangan model prediktif untuk pengadaan suku cadang di PLN Nusantara Power. Proses analisis ini bertujuan untuk memahami pola-pola dalam data pembelian suku cadang. Pola distribusi data dan agregat pembelian dalam setiap suku Cadang dilakukan pada proses ini. Selain itu, analisis eksploratif akan dilakukan untuk mengidentifikasi tren, anomali, atau pola yang menarik dalam data, yang dapat memberikan wawasan berharga dalam pengambilan keputusan.

III.6 *Modelling*

Pada tahap Modelling, model prediktif berbasis *Long Short-Term Memory* (LSTM) akan dikembangkan untuk memproyeksikan kebutuhan suku cadang di masa depan.

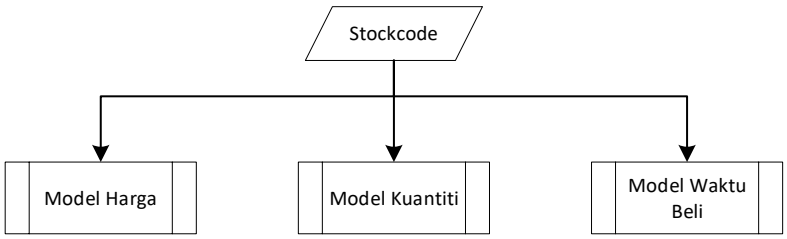

Gambar III.3 Pembuatan Model

Ada 3 jenis model yang akan dibuat pada tahap ini, yaitu:

1. Model Harga. Model ini akan melakukan prediksi terhadap harga *stockcode* ke depannya. Harga ini diprediksi dengan menggunakan data price setiap PO untuk masing-masing *stockcode*.
2. Model Kuantiti. Model ini akan melakukan prediksi kebutuhan jumlah yang dibutuhkan per *stockcode*. Kuantiti ini diprediksi dengan menggunakan jumlah pembelian pada setiap PO untuk masing-masing *stockcode.*
3. Model Waktu Beli. Model ini akan melakukan prediksi tanggal pembelian PO selanjutnya. Prediksi ini berdasarkan analisis pola tanggal pembelian *stockcode* dari waktu ke waktu.

Langkah-langkah dalam pengembangan model ini adalah inisiasi arsitektur LSTM yang sesuai, seperti jumlah *layer*, jumlah *unit*, jumlah *step* dan fungsi aktivasi yang optimal. Selain itu, data pembelian suku cadang akan dibagi menjadi set data pelatihan dan set data validasi/*testing* untuk melatih dan menguji kinerja model. Selama proses pelatihan, parameter model akan disesuaikan dan model akan diperbarui secara iteratif menggunakan algoritma pembelajaran yang sesuai, seperti algoritma backpropagation. Selanjutnya, model akan diuji menggunakan set data validasi untuk mengevaluasi kinerjanya, termasuk tingkat akurasi, kepekaan, dan spesifisitas. Hasil evaluasi ini akan digunakan untuk mengoptimalkan model dan memastikan bahwa model yang dihasilkan mampu memprediksi kebutuhan suku cadang dengan akurat dan andal.

III.7 Validasi dan Evaluasi

Pengukuran kinerja model dalam prediksi kebutuhan suku cadang di PLN Nusantara Power akan dilakukan menggunakan beberapa metrik evaluasi yang

mencakup *Mean Absolute Error* (MAE), *Mean Absolute Percentage Error* (MAPE), *Mean Squared Error* (MSE), dan *Root Mean Squared Error* (RMSE). MAE akan memberikan gambaran tentang kesalahan rata-rata antara nilai prediksi dan nilai sebenarnya, sementara MAPE akan mengukur kesalahan relatif dalam bentuk persentase. MSE akan memberikan pengukuran rata-rata kuadrat dari perbedaan antara prediksi dan nilai sebenarnya, sementara RMSE akan memberikan ukuran kesalahan rata-rata dalam satuan yang sama dengan variabel yang diprediksi. Penggunaan kombinasi metrik-metrik ini akan memberikan pemahaman yang komprehensif tentang kinerja model prediktif, memungkinkan untuk evaluasi yang lebih akurat dan pembandingan antara model yang berbeda.

III.8 Kesimpulan dan Saran

Pada akhir tahap penelitian akan dilakukan penarikan kesimpulan dan saran setelah diperolehnya pemecahan dari masalah penelitian. Kesimpulan akan menjawab rumusan masalah dan tujuan penelitian. Sedangkan saran akan memberikan masukan penyempurnaan untuk penelitian di masa depan.

DAFTAR PUSTAKA

Bloch, H., & Budris, A. R. (2021). Shop repair, spare parts availability & procurement.

Bhattacharyya, S.S., Kulkarni, O. and Mishra, A. (2023). Study of emerging avenues in supply chain resilience; the case of integration of additive manufacturing with spare parts procurement, Benchmarking: An International Journal, Vol. 30 No. 10, pp. 4100-4118.

Fadhilla Rahmi, L. (2022). Determination of Spare Parts Procurement in Plastic Packaging Manufacturing Company. In 5th International Conference in Industrial and Mechanical Engineering and Operations Management (IMEOM).

Sherstinsky, A. (2020). Fundamentals of recurrent neural network (RNN) and long short-term memory (LSTM) network, Physica D: Nonlinear Phenomena, Vol. 404, ISSN 0167-2789.

Salazar, J., Salinas, E., Flores, A., Alvarez, J., Hasachoo, N. (2022). Improving the level of service through an inventory management model for a spare parts marketing company. In: Tareq Ahram and Redha Taiar (eds) Human Interaction & Emerging Technologies (IHIET 2022): Artificial Intelligence & Future Applications. AHFE (2022) International Conference. AHFE Open Access, vol 68. AHFE International, USA.

Tingyu Xie, Shuting Tao, Qi Li, Hongwei Wang, and Yihong Jin. 2022. A lattice LSTM-based framework for knowledge graph construction from power plants maintenance reports. Serv. Oriented Comput. Appl. 16, 3 (Sep 2022), 167–177.

Jin, F., Hao, X., Yin, Z., Yang, C., Liu, X., & Shi, Y. (2023). An LSTM-PSO-based predictive strategy and its application in the main steam temperature control in power plants. Journal of Physics: Conference Series, Vol. 2564.

Samanazari, Mehdi & Flammini, Francesco & Santini, Stefania & Caporuscio, Mauro. (2023). A Systematic Literature Review on Transfer Learning for Predictive Maintenance in Industry 4.0. IEEE Access. PP. 1-1. 10.1109/ACCESS.2023.3239784.

Chen, Hanying & Gao, Puzhen & Tan, Sichao & Hongsheng, Yuan & Guan, Mingxiang. (2023). Prediction of Automatic Scram during Abnormal Conditions of Nuclear Power Plants Based on Long Short-Term Memory (LSTM) and Dropout. Science and Technology of Nuclear Installations, 2023, 1-14, 10.1155/2023/2267376.

Akhtar, Muhammad & Mekhilef, Saad & Mokhlis, Hazlie & Almohaimeed, Ziyad & Muhammad, Munir & Khairuddin, Anis & Akram, R. & Hussain, Majid. (2022). An Hour Ahead PV Power Forecasting Based on RNN-LSTM Model for Three Different PV Plants. Energies. 15. 10.3390/en15062243.

Leonardo, dos, Santos, Lima. (2022). Theory of Machine Learning with Limited Data.

Xiao, Wei. (2022). Information Theory and Machine Learning.

Zhou, Z.-H. (2021). Machine Learning (edisi ke-2). Springer.

Russell, S., & Norvig, P. (2020). Artificial Intelligence: A Modern Approach (edisi ke-4). Prentice Hall.

Bishop, C. M. (2021). Pattern Recognition and Machine Learning (2nd ed.). Springer.

Lapan, M. (2022). Deep Reinforcement Learning Hands-On (2nd ed.). Packt Publishing.

Hyndman, R. J., & Athanasopoulos, G. (2021). Forecasting: principles and practice (3rd ed.).

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press. ISBN: 0262035618.

LeCun, Yann & Bengio, Y. & Hinton, Geoffrey. (2015). Deep Learning. Nature. 521. 436-44. 10.1038/nature14539.

Heaton, J. (2015) Artificial Intelligence For Humans, Volume 3: Deep Learning and Neural Networks. ISBN: 978-1505714340.

Van Houdt, Greg & Mosquera, Carlos & Nápoles, Gonzalo. (2020). A Review on the Long Short-Term Memory Model. Artificial Intelligence Review. 53. 10.1007/s10462-020-09838-1.

Huang, Y., Hu, Y., Wu, L., Wen, S., & Wan, Z. (2024). Price prediction of power transformer materials based on CEEMD and GRU. Global Energy Interconnection, 7(2), 217-227.

Peraturan Menteri BUMN No. PER-05/MBU/2008 tentang Pedoman Umum Pengadaan Barang dan Jawa Badan Usaha Milik Negara.

Keputusan Direksi PT Pembangkitan Jawa-Bali No.100.DIR.2017 tentang Pedoman Umum Pengadaan Barang dan Jasa PT Pembangkitan Jawa-Bali.